

Сравнительный анализ современных генеративных моделей

Diffusion vs Transformers vs GANs

Имя: Dauren Esmuhanov

Группа: CSE-2402M

Университет: Astana IT University

Краткое введение: этот досье представляет полный обзор трёх основных классов генеративных моделей — GAN, диффузионные модели и трансформеры — с теорией, ключевыми реализациями, экспериментальным сравнением на одном датасете (Fashion-MNIST) и выводами о преимуществах, ограничениях и направлениях развития.

Зачем сравнивать генеративные модели?

Генеративные модели — один из наиболее динамичных разделов глубокого обучения. Их цель — аппроксимировать распределение данных $p(x)$ и генерировать новые, реалистичные образцы. В современных исследованиях и приложениях доминируют три класса архитектур:

- GAN — состязательное обучение генератора и дискриминатора.
- Diffusion Models — итеративное зашумление и обратное восстановление.
- Transformers — авторегрессионное или masked моделирование последовательности токенов, адаптированное для изображений с 2020 г..

Цель работы: теоретический обзор по двум моделям из каждого класса, реализация по одной модели каждого класса на Fashion-MNIST и сравнительный анализ по скорости, качеству, стабильности и гибкости.

GAN – принцип работы

GAN формулируются как минимаксная игра между двумя сетями:

Generator (G) принимает шум z и генерирует изображение $G(z)$, стремясь обмануть дискриминатор.

Discriminator (D) отличает реальные и сгенерированные примеры.

Формула мини-максного оптимума: $\min_G \max_D E[\log D(x)] + E[\log(1 - D(G(z)))]$.

Ключевые особенности и последствия:

- Инференс — один forward pass генератора: очень быстрое генерирование.
- Генератор получает сигнал только через градиенты дискриминатора (не видит реальные данные напрямую).
- Loss: BCE или Wasserstein.

Главные проблемы: mode collapse (потеря разнообразия), нестабильность обучения (колебания) и трудности количественной оценки (нет likelihood).

GAN — два ключевых поколения: DCGAN и StyleGAN2

DCGAN

Архитектурные принципы: свёртки вместо FC, ConvTranspose для апсэмплинга, BatchNorm (за исключением выхода/входа), ReLU в генераторе, LeakyReLU в дискриминаторе. Простой и стабильный дизайн для 28–128px изображений.

Типичный генератор: $z \in \mathbb{R}^{100} \rightarrow \text{Linear} \rightarrow \text{reshape} \rightarrow \text{несколько ConvTranspose} \rightarrow 1 \times 28 \times 28 \rightarrow \text{Tanh}$.

StyleGAN2

State-of-the-art для фотореалистичной генерации: Mapping Network ($z \rightarrow w$), weight modulation/demodulation, path-length regularization, отказ от progressive growing. Обеспечивает disentangled стили и высокое качество при 1024×1024.

Комментарий: DCGAN — лёгкая и обучаемая база для экспериментов; StyleGAN2 — высококачественный, но более сложный и вычислительно тяжёлый подход.

Diffusion – принцип работы

Диффузионные модели описывают два процесса:

1. Forward process (зашумление): по шагам $t=1..T$ к x_0 добавляется гауссов шум с расписанием β_t : $q(x_t | x_{t-1}) = N(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$.
Благодаря свойствам гаусса можно выразить x_t напрямую через x_0 и шум ϵ : $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1-\alpha_t} \epsilon$, где $\alpha_t = \prod_{i=1}^t (1-\beta_i)$.
2. Reverse process (восстановление): сеть $\epsilon_\theta(x_t, t)$ обучается предсказывать шум ϵ ; обучение по упрощённой MSE: $L = E[||\epsilon - \epsilon_\theta(x_t, t)||^2]$.
Сэмплинг начинается с $x_T \sim N(0, I)$ и итеративно приближает x_0 .

Ключевые свойства: стабильное обучение (без adversarial динамики), высокое качество и разнообразие, но дорогой по времени инференс (T шагов, обычно 200–1000).

Diffusion — две ключевые реализации: DDPM и Latent Diffusion



DDPM

Базовая U-Net архитектура с time-conditioning (sinusoidal embeddings), линейное beta-расписание. Показала, что диффузия конкурентна GAN по качеству генерации (низкие FID на CIFAR-10).



Latent Diffusion / Stable Diffusion

Идея: перевод диффузии в латентное пространство (кодирование VAE), применение диффузии к сжатому латенту, декодирование обратно. Экономит вычисления, делает возможным text-to-image через cross-attention и classifier-free guidance.

Комментарий: DDPM — теоретическая база, LDM — практическая масштабируемость и основа современных text-to-image систем.

Transformers для генерации изображений — принцип

Трансформеры представляют изображение как последовательность токенов и моделируют $p(x)$ через факторизацию по токенам. Основные компоненты:

- Token embedding + positional embedding.
- Causal self-attention (маска) для авторегрессии.
- FFN с GELU, линейная голова $\rightarrow$ softmax и cross-entropy loss.

Плюсы: стабильное обучение (teacher forcing), простота условной генерации через prompt/context, предсказуемый выигрыш при масштабировании (scaling laws). Минус — авторегрессивный инференс требует N шагов для N токенов, что замедляет генерацию для больших разрешений.

Transformers — iGPT и DiT



iGPT

Авторегрессионный генератор пикселей: разворачивание изображения в 1D последовательность, квантизация цветов в словарь (k-means), GPT-архитектура обучается предсказывать следующий токен. Масштабирование до миллиардов параметров даёт конкурентное качество, но генерация медленная.

Комментарий: DiT иллюстрирует тенденцию смешивать преимущества трансформеров и диффузий — масштабируемая backbone-модель с высококачественным шумоподавлением.



DiT — Diffusion Transformer

Гибрид: трансформер заменяет U-Net в диффузионной схеме. Патчи → токены, adaLN-Zero для timestep/class conditioning. Масштабирование улучшает FID; DiT-XL достиг SOTA на ImageNet 256×256.

Сравнение: таблица характеристик

Критерий	GAN	Diffusion	Transformer
Принцип обучения	Adversarial (min-max)	Denoising / score matching (MSE)	Autoregressive / masked (CE)
Loss-функция	BCE / Wasserstein	MSE (noise prediction)	Cross-Entropy (next token)
Скорость инференса	Очень быстрая (1 forward)	Очень медленная (Т итераций)	Медленная (N шагов)
Качество	Высокое, но риск mode collapse	Очень высокое, большое разнообразие	Высокое при масштабе
Стабильность обучения	Нестабильная	Стабильная	Стабильная
Гибкость	Ограниченная	Высокая (guidance, cross-attention)	Очень высокая (prompt, context)

Ключевые выводы: GAN — чемпион по скорости инференса; Diffusion — лидер по качеству и разнообразию; Transformer — мощь масштабирования и естественная интеграция условностей.

Эксперимент: дизайн, результаты, выводы и placeholders изображений

Дизайн эксперимента

Датасет: Fashion-MNIST (60k, 28×28, grayscale)
Устройство: CPU (Apple Silicon)
Batch size: 128
LR: 2×10⁻⁴ (Adam)
Эпохи: 5
Фреймворк: PyTorch 2.10

Модели (реализация)


- DCGAN — стандартный ConvTranspose генератор и Conv дискриминатор; Loss: BCEWithLogitsLoss.
- DDPM — SimpleUNet c time conditioning, 200 timesteps, linear beta schedule.
- Image Transformer — 4-слой decoder-only, embed_dim=128, 196 токенов (14×14), словарь=16, Cross-Entropy.

Ключевые численные результаты


Модель	Время обучения	Инференс (64)	Отн. скорость инференса
DCGAN	1402s (~23 мин)	0.019s	1.0× (baseline)
DDPM	3574s (~60 мин)	48.0s	2526× медленнее
Transformer	1921s (~32 мин)	13.8s	728× медленнее

Потери и визуальные результаты


Кривые потерь:



- график Generator/Discriminator loss за 5 эпох.



- график MSE loss за 5 эпох.



- график Cross-Entropy loss за 5 эпох.


Сгенерированные изображения:




- сетка 8×8 результатов DCGAN.



- сетка 8×8 результатов DDPM.



- сетка 8×8 результатов Image Transformer.



- bar charts: сравнение времени обучения и инференса.

Короткие выводы и перспективы

Вывод 1 — Скорость

DCGAN — лучший по инференсу (миллисекунды). DDPM — самый медленный из-за Т итераций. Transformer — промежуточно, но авторегрессия замедляет при длинных последовательностях.

Вывод 2 — Качество

DDPM показывает более высокое разнообразие и качество образцов; GAN склонен к mode collapse; Transformer ограничен квантизацией и размером модели при данной реализации.

Перспективы

Гибридные подходы становятся стандартом: Transformer backbone + Diffusion process + GAN-дистилляция для ускорения. Технологии ускорения диффузии (DDIM, DPM-Solver, Consistency Models) и латентные подходы делают диффузии практически применимыми.

Практические рекомендации и будущее

Выбор генеративной модели должен определяться конкретными требованиями задачи. Если приоритетом является скорость инференса для приложений реального времени, GANы, такие как DCGAN, остаются отличным выбором благодаря своей однократной генерации. Их ограничения в стабильности и риске mode collapse следует учитывать при проектировании.

Для задач, где критичны высокое качество, детализация и разнообразие генерируемых данных (например, для создания высокохудожественных изображений или расширения датасетов), диффузионные модели (DDPM) показывают наилучшие результаты. Хотя их традиционно медленный инференс был недостатком, современные методы ускорения значительно улучшают их практическую применимость.

Трансформеры выделяются своей гибкостью и способностью работать с длинными последовательностями и сложными условиями, что делает их идеальными для задач, где требуется точный контроль над генерацией или мультимодальные входные данные. Их масштабируемость открывает путь к созданию всё более мощных и универсальных моделей.

Будущее генеративных моделей тесно связано с развитием технологий ускорения. Прогресс в таких методах, как DDIM, DPM-Solver и Consistency Models, превращает некогда медленные диффузионные модели в инструменты, применимые в реальных сценариях. Эти инновации, наряду с гибридными архитектурами, позволяют нам получать лучшее от каждой парадигмы, создавая более эффективные, качественные и управляемые генеративные системы.